

Representação de Números Reais

- Sistema de Numeração Binário:

- Sistema posicional:

...	—	—	—	—	—	—	—	■	—	—	—	—	...
...	2^6	2^5	2^4	2^3	2^2	2^1	2^0		2^{-1}	2^{-2}	2^{-3}	2^{-4}	...
...	64	32	16	8	4	2	1		0.5	0.25	0.125	0.0625	...

- Exemplo: $011.011_2 = 3.375_{10}$

Floating Point

- **Representação com ponto flutuante (FP):**
 - Usada para representar n^{os} reais
- **Notação científica:**
 - Possui um único dígito à esquerda do ponto decimal
 - **Exemplos** (base 10):
$$1.0_{\text{dez}} \times 10^{-9}$$
$$3.15576_{\text{dez}} \times 10^9$$
- **Notação científica normalizada:**
 - Não possui zeros não significativos à esquerda
 - **Exemplos** (base 10):
 - Normalizado: $4.0_{\text{dez}} \times 10^{-9}$
 - Não normalizados: $0.4_{\text{dez}} \times 10^{-8}$
$$0.04_{\text{dez}} \times 10^{-7}$$
 - **Exemplo** (base 2): Ponto binário
 - Normalizado: $1.0_{\text{dois}} \times 2^{-1}$

Representação com FP

- Usa notação científica normalizada, na base 2

- **Vantagens:**

- Cada valor possui apenas uma representação
- Padronização
- Simplifica operações aritméticas
- Aumenta precisão dos valores que podem ser representados

- **Representação:**

$$N^o = +1.XXX_{dois} \times 2^{YYY} \quad \text{ou} \quad N^o = -1.XXX_{dois} \times 2^{YYY}$$

- **Significando** = $1.XXX$

- **Fração** = XXX

- **Expoente** = YYY


- **Ponto flutuante:** Ponto binário não está fixo

Exemplo:


$$\begin{array}{r} 1.0000 \times 2^2 \\ + 1.0000 \times 2^2 \\ \hline 10.0000 \times 2^2 \\ 1.0000 \times 2^3 \end{array}$$

Representação com FP (Padrão FP IEEE 754)

- **FP de precisão simples:** 32 bits



- **FP de precisão dupla:** 64 bits



- **Campo *S*:** Sinal do n^o FP $\Rightarrow$ positivo (0) ou negativo (1)
- **Campo *E*:** expoente com sinal (**representado com notação *biased***)
- **Campo *F*:** fração (1 mais à esquerda do significando não é representado)
- **Número** = $(-1)^S \times (1 + F) \times 2^E$

Representação com FP

- **Compromisso:**

- Precisão (n^o de bits da fração) $\times$ *range* (n^o de bits do expoente)

- **Overflow/Underflow:**

- Expoente é n^o **positivo/negativo** de valor absoluto muito grande para ser representado no campo E

- **Range do expoente:**

- FP de precisão simples: -126 a $+127$
- FP de precisão dupla: -1022 a $+1023$

- **Representação de valores especiais:**

	S	E	F
0.0	0	0000	0000
$-\infty$	1	1111	0000
$+\infty$	0	1111	0000

Representação com FP com Notação *Biased*

- Para comparar n^{os} FP com instruções de comparação de inteiros:
 - Campo expoente na parte mais significativa que campo fração
 - Representar:
 - Expoente mais negativo como 000...01
 - Expoente mais positivo como 111...10
- **Bias**: valor subtraído do campo E para obter valor real do expoente
 - FP de precisão simples: $Bias = 127$
 - FP de precisão dupla: $Bias = 1023$

$$\text{Expoente} = E - Bias \implies$$

$$E = \text{Expoente} + Bias$$

$$N^{\circ} = (-1)^S \times (1 + F) \times 2^{(E - Bias)}$$

S	E	F
-----	-----	-----

FP de precisão simples		
Expoente	E	
-126	1_{10}	0000 0001
-125	2_{10}	0000 0010
$\vdots$	$\vdots$	$\vdots$
-1	126_{10}	0111 1110
0	127_{10}	0111 1111
+1	128_{10}	1000 0000
$\vdots$	$\vdots$	$\vdots$
+127	254_{10}	1111 1110

Exemplo 1: Converter -0.75_{dez} para Binário FP

- $N^o = -0.75_{dez} = -0.11_{dois}$

$$0.75 \times 2 = 1.5 \quad \text{parte inteira } 1 \Leftarrow \text{bit mais significativo}$$

$$0.5 \times 2 = 1.0 \quad \text{parte inteira } 1 \Leftarrow \text{bit menos significativo}$$

- Em notação científica normalizada: $-1.1_{dois} \times 2^{-1}$

- Precisão simples: $Bias = 127$

- $S = 1$

- Expoente = -1

- $E = \text{Expoente} + Bias = -1 + 127 = 126_{dez} = 01111110_{dois}$

- $F = .100000000000000000000000_{dois}$

<i>S</i>	<i>E</i>	<i>F</i>
1	01111110	100000000000000000000000
8 bits		23 bits

Exemplo 2: Converter 0.1_{dez} para Binário FP

- $N^o = 0.1_{dez} = 0.0001100110011\dots_{dois}$

0.1 $\times 2 = 0.2$ parte inteira 0 $\Leftarrow$ bit mais significativo

0.2 $\times 2 = 0.4$ parte inteira 0


0.4 $\times 2 = 0.8$ parte inteira 0

0.8 $\times 2 = 1.6$ parte inteira 1

0.6 $\times 2 = 1.2$ parte inteira 1

0.2 $\times 2 = 0.4$ parte inteira 0 $\Leftarrow$ repete padrão 0011

- Em notação científica normalizada: $1.10011001100\dots_{dois} \times 2^{-4}$
- Precisão simples: $Bias = 127$
 - $S = 0$
 - $E = \text{Expoente} + Bias = -4 + 127 = 123_{dez} = 01111011_{dois}$
 - $F = .10011001100110011001100_{dois}$



Exemplo 3: Converter Binário FP para Decimal

S	E	F
1	10000001	010000000000000000000000
	8 bits	23 bits

- Precisão simples: $Bias = 127$
 - $S = 1 \implies$ Número negativo
 - $E = 10000001 = 129 \implies \text{Expoente} = E - Bias = 129 - 127 = 2_{dez}$
 - $F = .010000000000000000000000_{dois} \implies \text{Significando} = 1.01$
- $N^o = -1.01_{dois} \times 2^2$
 $= -1.25_{dez} \times 4 = -5.0$

Operação de Soma FP

- **Exemplo** (base 10): $9.999_{dez} \times 10^1 + 1.610_{dez} \times 10^{-1}$

- Significando: 4 dígitos

- **Passos:**

1. Alinhar ponto decimal do n^o com menor expoente, para ficar com expoente igual ao outro n^o :

$$1.610_{dez} \times 10^{-1} = 0.01610_{dez} \times 10^1 \cong 0.016_{dez} \times 10^1$$

2. Somar significandos:

$$9.999_{dez} + 0.016_{dez} = 10.015_{dez} \Rightarrow \text{Soma} = 10.015_{dez} \times 10^1$$

3. Normalizar soma:


$$10.015_{dez} \times 10^1 = 1.0015_{dez} \times 10^2$$

4. Arredondar significando da soma:


$$1.0015_{dez} \times 10^2 \cong 1.002_{dez} \times 10^2$$

Se necessário, normalizar soma novamente (repetir passo 3)

Algoritmo de Soma FP



Hardware para Soma FP



Exemplo 4: Soma FP

- $0.5_{dez} + (-0.4375_{dez}) = 1.000_{dois} \times 2^{-1} + (-1.110_{dois} \times 2^{-2})$

- Significando: 4 bits

- **Passos:**

1. Shifta significando do n^o com menor expoente para direita até ficar com expoente igual ao outro n^o :

$$-1.110_{dois} \times 2^{-2} = -0.111_{dois} \times 2^{-1}$$

2. Soma significandos:

$$1.000_{dois} + (-0.111_{dois}) = 0.001_{dois} \Rightarrow \text{Soma} = 0.001_{dois} \times 2^{-1}$$

3. Normaliza soma e checa overflow e underflow:

$$0.001_{dois} \times 2^{-1} = 0.010_{dois} \times 2^{-2} = 0.100_{dois} \times 2^{-3} = 1.000_{dois} \times 2^{-4}$$

4. Arredonda significando da soma: não muda nada

- $\text{Soma} = 1.000_{dois} \times 2^{-4} = \frac{1}{2^4} = 0.0625_{dez}$