




Threads e Multithreading

- **Thread:**
 - Fluxo de execução sequencial dentro de um programa
- **Programa sequencial:**
 - Possui uma única thread
- **Programa multithreaded:**
 - Possui várias threads
 - Threads compartilham área de código e dados do programa
 - Cada thread possui sua área de pilha e conjunto de registradores



Processador Superscalar SEM Multithreading

- Situação:
 - FUs do processador ociosas nos ciclos em que programa está em stall
 - Em geral, programa não apresenta **ILP** (**I**nstruction **L**evel **P**aralelism) suficiente para manter todas as FUs ocupadas em todos os ciclos




Execução de instruções da thread **1**

Multithreading

- **Ideia:**
 - Permitir que várias threads do **mesmo programa** compartilhem processador, executando concorrentemente
- **Multithreading:**
 - Técnica que permite execução intercalada de múltiplas threads do **mesmo programa** em um único processador
- **Objetivo:** Explorar **Thread Level Parallelism** (TLP)
- Troca de contexto entre threads deve ser rápida $\Rightarrow$
Realizada pelo hardware (em geral)
- Multithreading $\neq$ Multiprogramação
- **Formas de implementação** de multithreading:
 - Multithreading de granularidade grossa
 - Multithreading de granularidade fina
 - Simultaneous Multithreading

Multithreading de Granularidade Grossa


- Troca thread em execução somente quando ocorre stall longo (por exemplo, falha na cache L2)
- Troca de contexto entre threads não precisa ser tão rápida
- **Vantagem:** Não torna execução de uma thread individual mais lenta
- **Desvantagem:** Não “esconde” perda de throughput causada por stalls curtos



Execução de instruções das threads **1** e **2**

Multithreading de Granularidade Fina


- Troca thread em execução a cada ciclo:
 - Execução de várias threads é intercalada (por exemplo, com round-robin)
 - “Pula” threads em stall
- Troca de contexto entre threads deve ter overhead muito baixo
- **Vantagem:** “Esconde” perda de throughput causada por stalls curtos e longos
- **Desvantagem:** Torna execução de uma thread individual mais lenta



Execução de instruções das threads 1, 2, 3 e 4

Simultaneous Multithreading


- **Ideia:** Simultaneous Multithreading
 - Explorar ILP e TLP de forma integrada
 - Despachar instruções de diferentes threads (de um mesmo programa), em um mesmo ciclo
- Mecanismos de despacho múltiplo dinâmico, escalonamento dinâmico e renomeação de registradores facilitam implementação de Simultaneous Multithreading



Execução de instruções das threads 1, 2, 3 e 4


Simultaneous Multithreading: Intel Hyper-Threading

- **Em um único núcleo:**
 - Instruções de **2** diferentes threads (do mesmo programa) podem ser executadas ao mesmo tempo, em unidades funcionais diferentes
- **Núcleo físico $\neq$ núcleo lógico ou virtual**



Arquiteturas Multicore


- **Situação:**
 - Obter melhor desempenho aumentando frequência do clock $\Rightarrow$ Superaquecimento
- **Ideia:**
 - Colocar 2, 4 ou mais processadores (núcleos ou cores) em um mesmo chip $\Rightarrow$ Arquiteturas dual-core, quad-core e multicore
- **Cada núcleo:**
 - Implementa pipeline, superscalar, simultaneous multithreading, ...
 - Executa threads **concorrentemente**
- **Diferentes núcleos:**
 - Executam threads **paralelamente**
- **Objetivo:** Explorar mais TLP




Hierarquia de Memórias do Processador Multicore

- **Núcleos conectados a uma memória compartilhada**, através de rede de interconexão (por exemplo, um barramento)
 - Todos os núcleos têm acesso a qualquer posição da memória
- Núcleos compartilham interconexão com resto do sistema (barramento para memória e E/S)
- **Caches L1**: cada núcleo possui caches L1 separadas
- **Caches L2 e L3**:
 - Compartilhadas entre os núcleos; ou
 - Cada núcleo possui caches separadas
- Arquitetura multicore:
 - Pode ser vista como um multiprocessador com memória centralizada
 - Vantagem sobre multiprocessador:
 - Maior proximidade dos núcleos $\Rightarrow$ Melhor desempenho

Processador convencional (single-core)



Processador multicore com cache L2 compartilhada



Processador multicore com caches L2 separadas

